Machine Learning

Fernando Nemec

Regressão Logística

Uma regressão logística funciona como uma regressão linear. De fato, trata-se de um regressor, definitivamente.

Contudo, o termo de resposta de uma regressão logística é modelado, através da ativação de uma função sigmoide, para representar um intervalo de resposta entre [0,1].

Função Sigmoide

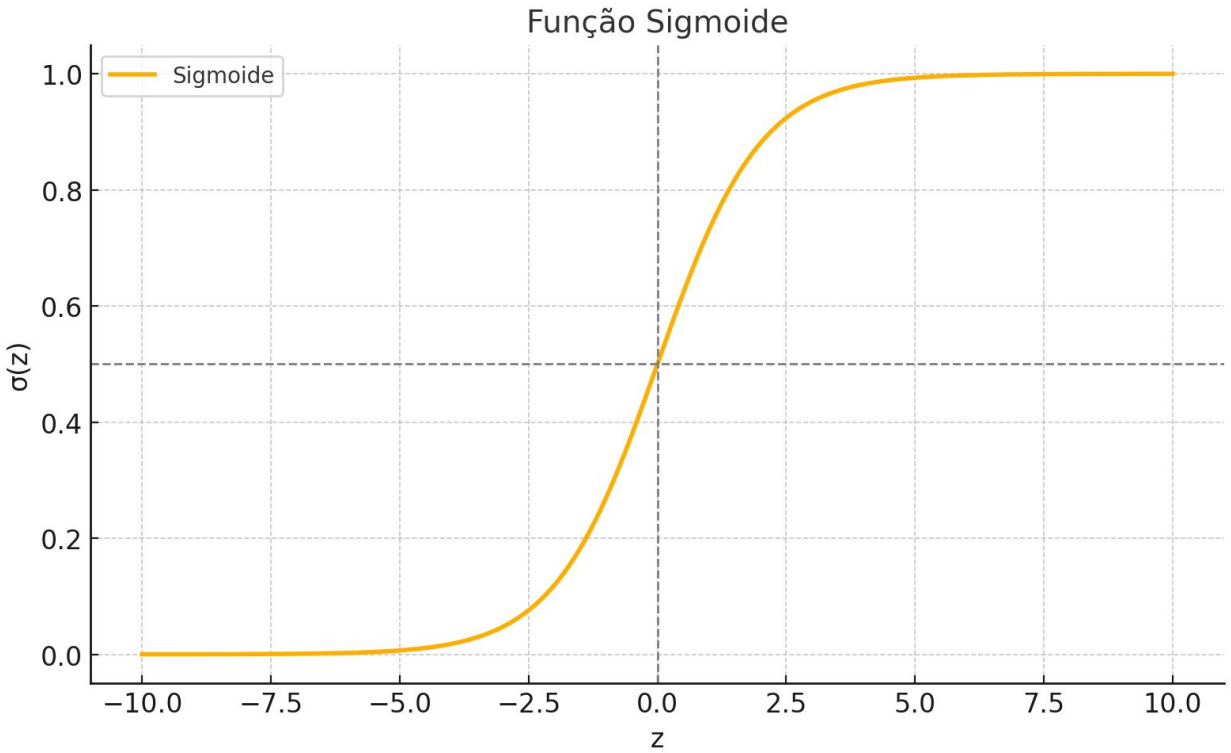

Principais diferenças entre Linear e Logística

Característica	Regressão Linear	Regressão Logística
Objetivo	Predizer valores contínuos	Classificar em categorias (geralmente 0 ou 1)
Tipo de variável resposta	Numérica contínua (ex: preço, nota)	Categórica binária (ex: aprovado/reprovado)
Equação	$y = \beta_0 + \beta_1 x_1 + \dots$	$p = \frac{1}{1+e^{-(\beta_0+\beta_1 x_1+\dots)}}$
Faixa de saída	$-\infty$ a $+\infty$	0 a 1 (interpretação como **probabilidade**)
Função de ativação	Nenhuma (é linear)	Sigmóide
Erro minimizado	Erro quadrático (MSE)	Log-loss (ou cross-entropy)
Interpretação dos coeficientes	Variação na média de y	Variação nos log-odds da classe 1

Regressão Logística

A partir da modulação do seu termo de resposta pela ativação da função sigmoide, uma regressão logística passa, de fato, a funcionar como um classificador.

Por esse ponto de vista, trata-se de um classificador bastante usado e robusto matematicamente.

Regressão Logística

Vantagens:

1. Fácil de implementar e baixo custo de processamento.
2. Fácil de interpretar através de coeficientes.

Desvantagens:

1. Sem especialização, não consegue trabalhar com multiclasses.
2. Espera linearidade da variável de interesse.

Regressão Logística

Quando usar? Em problemas mais simples, onde é necessário um algoritmo bem estudado e confiável ou quando é necessário buscar inferência.

Quando não usar? Quando não há tempo para explorar as features do dataset ou quando a máxima performance do modelo é necessária.

Por que não usamos regressão linear para classificação?

Problema:

1. A regressão linear pode gerar saídas fora do intervalo [0,1][0,1]
2. Ela minimiza o erro quadrático (MSE), o que não funciona bem para variáveis binárias
3. Não lida bem com desbalanceamento nem com classes como objetivo

Consequência:

1. Não interpreta o resultado como probabilidade
2. Não é uma boa base para classificação binária

Por que usamos a sigmoide na regressão logística?

1. Transforma a saída linear Z (que vai de −∞ a +∞) em uma probabilidade entre 0 e 1
2. Gera uma curva suave, contínua e derivável

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

Por que o Gradiente Descendente precisa disso?

1. A função step (0 ou 1 direto) cria descontinuidades
2. A sigmoide permite o uso de funções de perda suaves (como cross-entropy)
3. Isso garante gradientes bem definidos, necessários para ajustar os pesos

Matriz de Confusão

	Predito 0	Predito 1
Real 0	TN	FP
Real 1	FN	TP

- **TP (Verdadeiro Positivo)**: Acertou que era 1
- **TN (Verdadeiro Negativo)**: Acertou que era 0
- **FP (Falso Positivo)**: Errou — disse que era 1, mas era 0
- **FN (Falso Negativo)**: Errou — disse que era 0, mas era 1

Métricas de Avaliação

Acurácia: Proporção de acertos em relação ao total de previsões.

Boa quando: classes estão balanceadas.

Cuidado: pode ser enganosa em datasets desbalanceados!

$$\text{Acurácia} = \frac{\text{nº de acertos}}{\text{nº total de casos}}$$

Métricas de Avaliação

Precisão (Precision): Dos casos que o modelo previu como positivos, quantos eram realmente positivos?

Boa quando: o custo de falso positivo é alto (ex: diagnóstico de doença rara).

$$\text{Precisão} = \frac{TP}{TP + FP}$$

Métricas de Avaliação

Recall (Sensibilidade): Dos casos realmente positivos, quantos o modelo detectou?

Boa quando: o custo de falso negativo é alto (ex: não identificar fraude).

$$\text{Recall} = \frac{TP}{TP + FN}$$

Métricas de Avaliação

F1-Score: Média harmônica entre precisão e recall. Equilibra os dois.

Boa quando: precisa equilibrar precisão e recall, ideal para dados desbalanceados.

$$F1 = 2 \cdot \frac{\text{Precisão} \cdot \text{Recall}}{\text{Precisão} + \text{Recall}}$$

Balanceamento de Classes – Por que e Como?

O problema: quando uma classe aparece muito mais que a outra, o modelo pode aprender a ignorar a minoria e ainda assim ter alta acurácia.

Exemplo:

95% dos dados = classe 0

5% = classe 1

Um modelo que sempre prevê 0 teria 95% de acurácia... e zero utilidade.

Por que balancear?

1. Para ensinar o modelo a reconhecer padrões raros
2. Para que métricas como F1-score e recall façam sentido
3. Para evitar viés do modelo em favor da classe majoritária

Técnicas de Balanceamento

Estratégia	Descrição
Oversampling	Aumenta a quantidade de exemplos da classe minoritária (duplicação ou SMOTE)
Undersampling	Reduz a quantidade de exemplos da classe majoritária
SMOTE	Gera novos dados sintéticos da classe minoritária usando interpolação
Class weights	Penaliza mais os erros da classe minoritária durante o treino